



**U N I V E R S I D A D
D E L A F R O N T E R A**

Informe: Aprendizaje por Refuerzo aplicado a Detección de Anomalías mediante una Aplicación Web

Alumno: Gustavo Pérez
Curso: Sistemas Inteligentes
Profesora: Dr. Ricardo Gacitúa B.
Fecha: 10 de Julio, 2026

1. Introducción

El Aprendizaje por Refuerzo (Reinforcement Learning, RL) es un paradigma del aprendizaje automático en el que un agente aprende a tomar decisiones interactuando con un entorno, en lugar de aprender a partir de ejemplos etiquetados de antemano (IBM, 2024; Amazon Web Services, s. f.; Sutton & Barto, 2018). A diferencia del aprendizaje supervisado, donde un modelo aprende a predecir una respuesta correcta conocida, o del no supervisado, donde se buscan patrones en datos sin etiquetar, el RL aprende a actuar: el propio agente genera sus experiencias probando acciones, observando sus consecuencias y ajustando su comportamiento en función de una señal numérica de recompensa.

Este proyecto tiene como principal objetivo presentar de forma clara y progresiva los fundamentos del Aprendizaje por Refuerzo mediante una aplicación web educativa.

2. Conceptos fundamentales del Aprendizaje por Refuerzo

Todo problema de RL puede describirse con seis elementos básicos que interactúan en un ciclo continuo (Sutton & Barto, 2018):

- **Agente:** el sistema autónomo que percibe el entorno, decide qué acción tomar y aprende de las consecuencias de esa acción.
- **Entorno:** todo lo externo al agente; define las reglas, los límites y las consecuencias posibles de cada acción.
- **Estado (S):** la representación del entorno en un instante determinado, es decir, la información que el agente percibe antes de decidir.
- **Acción (A):** cada uno de los movimientos que el agente puede ejecutar sobre el entorno.
- **Recompensa (R):** la señal numérica que el entorno entrega tras cada acción, indicando qué tan buena o mala fue esa decisión.
- **Política (π):** la estrategia aprendida por el agente, que asigna a cada estado la acción más conveniente.

3. Algoritmo: Q-Learning

Este proyecto utiliza Q-Learning, uno de los métodos más conocidos y adecuados cuando el número de estados y acciones es manejable (Watkins, 1989; Goyal, 2023). Q-Learning estima, para cada par estado-acción, cuánta recompensa total puede esperar el agente si toma esa acción en ese estado. Estos valores se almacenan en una tabla Q, donde cada fila representa un estado y cada columna una acción.

Tras cada acción, el valor correspondiente se actualiza con la siguiente regla:

$$Q(s, a) \leftarrow Q(s, a) + \alpha \cdot [r + \gamma \cdot \max_{s'} Q(s') - Q(s, a)]$$

Donde α (alfa) es la tasa de aprendizaje, γ (gamma) el factor de descuento que pondera las recompensas futuras, r la recompensa recibida y $\max Q(s')$ la mejor estimación disponible desde el siguiente estado. Al principio del entrenamiento todos los valores Q son cero, ya que el agente no sabe nada del entorno; a medida que interactúa y recibe recompensas, la tabla converge y refleja, para cada estado, cuál es la acción más conveniente.

Para decidir qué acción tomar en cada paso se usa una política ϵ -greedy: con probabilidad ϵ el agente explora eligiendo una acción al azar, y con probabilidad $1-\epsilon$ explota eligiendo la acción con mayor valor Q conocido. El valor de ϵ disminuye gradualmente a lo largo del entrenamiento, de modo que el agente explora más al inicio y explota más una vez que ha aprendido.

4. Caso práctico: detección de anomalías en tráfico vehicular

Para ilustrar cómo el RL puede aplicarse a la detección de anomalías, se modela una intersección urbana monitoreada por sensores. El agente observa lo que los sensores reportan y decide qué tipo de respuesta corresponde, aprendiendo por experiencia a distinguir el tráfico normal de las situaciones anómalas.

Estado, acciones y recompensa

Cada estado combina tres variables detectadas por el sensor: el nivel de flujo vehicular (bajo, medio, alto), el patrón de circulación (normal, irregular) y el tipo de incidente activo (ninguno, exceso de velocidad, vehículo a contraflujo, bloqueo de intersección). Esta combinación produce 24 estados posibles.

Frente a cada estado el agente puede elegir una de cuatro acciones, de menor a mayor severidad: marcar como normal, emitir una alerta leve, emitir una alerta crítica, o activar un protocolo de emergencia. La recompensa depende de qué tan bien la acción elegida coincide con la severidad real de la situación:

- **+2** si la acción coincide exactamente con la severidad real del estado.
- **-1** si la acción está un nivel por encima o por debajo del correcto (sobre- o sub-reacción leve).
- **-3** si la acción está muy alejada de lo correcto (por ejemplo, ignorar una emergencia o activar el protocolo de emergencia ante tráfico normal).

Simulador interactivo

La aplicación incluye un simulador donde el usuario puede ajustar los hiperparámetros del algoritmo y entrenar al agente en tiempo real, observando su evolución mediante tres visualizaciones: un gráfico de recompensa acumulada por episodio, la tabla Q completa y una animación esquemática de la intersección que refleja el estado y la acción elegida en cada paso. Además, un modo comparativo permite al usuario enfrentarse al agente ya entrenado, eligiendo su propia respuesta ante los mismos estados y comparando su desempeño con el del agente.

5. Diseño de la aplicación web

Para reforzar el objetivo educativo del proyecto, el contenido teórico no se presenta como una página de scroll continuo, sino como una secuencia de diapositivas navegable con los puntos del menú, el teclado o gestos táctiles en dispositivos móviles. Esta estructura ayuda a que el usuario procese un concepto a la vez antes de avanzar al siguiente, en lugar de enfrentarse a un bloque largo de texto.

Dentro de esas diapositivas se incorporaron tres tipos de elementos interactivos, pensados específicamente para que el usuario aplique cada concepto en el momento en que lo está leyendo, en lugar de solo leerlo:

1. **Simulaciones en contenidos:** por ejemplo, un control deslizante de ϵ en la sección de exploración/explotación, que permite mover la probabilidad de explorar y simular decisiones del agente ahí mismo.
2. **Calculadora de la ecuación de Bellman:** junto a la fórmula de actualización de Q-Learning, un panel permite modificar $Q(s,a)$, α , r , γ y $\max Q(s')$ y ver de inmediato el nuevo valor calculado, para que el usuario pueda entender como cada valor afecta al resultado de la fórmula.
3. **Mini-quiz de comprensión por sección:** cada tema cuenta con un pequeño quiz con 2 o 3 preguntas de opción múltiple con retroalimentación inmediata, accesibles mediante un botón flotante que abre un panel superpuesto.

El caso práctico, además, termina con un llamado a la acción explícito hacia el simulador completo, describiendo en un par de líneas qué va a encontrar ahí (hiperparámetros ajustables, tabla Q en vivo, gráfico de recompensa y modo comparativo).

6. Conclusiones y limitaciones

El proyecto muestra cómo el Aprendizaje por Refuerzo permite entrenar un agente para tomar decisiones sin depender de ejemplos etiquetados: en lugar de memorizar respuestas correctas, el agente explora el entorno, recibe recompensas y ajusta su política hasta actuar de forma coherente con el objetivo del problema. Aplicado a la intersección vehicular, el agente aprende a escalar su respuesta desde “normal” hasta “emergencia” de acuerdo con la severidad real de cada situación, penalizando tanto la subreacción como la sobrereacción.

Referencias

- Amazon Web Services. (s. f.). *What is reinforcement learning?* aws.amazon.com/es/what-is/reinforcement-learning
- Goyal, S. (2023, 24 de marzo). *Introducción a Q-Learning: aprendizaje por refuerzo*. freeCodeCamp. freecodecamp.org/espanol/news/introduccion-a-q-learning-aprendizaje-por-refuerzo
- IBM. (2024). *What is reinforcement learning?* ibm.com/es-es/think/topics/reinforcement-learning
- Sutton, R. S., y Barto, A. G. (2018). *Reinforcement learning: An introduction* (2.^a ed.). MIT Press. incompleteideas.net/book/the-book-2nd.html
- Watkins, C. J. C. H. (1989). *Learning from delayed rewards* [Tesis doctoral, University of Cambridge].